Guion de exposición (15 minutos) y ajuste al póster

Congreso: Quinto Congreso de Ingeniería, Desarrollo Humano y Sostenibilidad Global. Formato: póster de 70 × 100 cm (plantilla `Plantilla_póster_2026-OTH.pptx`).

Reparto del tiempo

Expositor	Tiempo	Tema	Recuadro del póster que señala
Gabriel Aldana	0:00–3:30	Problema, objetivos, datos y la regla de no mirar el futuro	Introducción
Harold Fúneme	3:30–7:30	Teoría de los modelos de pronóstico (econometría, ML y redes)	Metodología (parte 1)
Laura Rodríguez	7:30–11:00	Cómo se comparan los modelos (teoría de las pruebas) y resultados de pronóstico	Metodología (parte 2) y Resultados
Juan Roa	11:00–14:30	Teoría de riesgo y portafolios, resultados de inversión, agente de IA y conclusiones	Resultados y Conclusiones
—	14:30–15:00	Margen para transiciones o una pregunta	—

El reparto de nombres es una propuesta: cámbienlo según quién domine cada tema. Cada parte dura unos 3:30 (unas 450 palabras habladas). Los recuadros azules son lo que se dice en voz alta; los verdes, marcados **Teoría**, son la parte que recomendó el profesor. Si van cortos de tiempo, digan solo la idea en negrita y salten la fórmula.

Expositor 1 — Gabriel: problema, datos y regla de oro (3:30)

[Señalar el título y el recuadro de Introducción]

Buenos días. Nuestra pregunta es: **¿los modelos más sofisticados, como las redes neuronales, sirven de verdad para invertir en acciones colombianas?**

Hoy es muy común ver estudios donde un modelo de inteligencia artificial "le gana al mercado". El problema es que muchas veces esa victoria se consigue usando, sin querer, información del periodo que se está evaluando. Nosotros planteamos el estudio de forma conservadora: todo modelo tenía que ganarle a una referencia simple, en datos que nunca había visto, y con pruebas estadísticas serias.

Trabajamos con **nueve acciones de la Bolsa de Valores de Colombia**, de enero de 2020 a septiembre de 2026: Ecopetrol, Celsia, Davivienda, Banco de Bogotá, Grupo Bolívar, Promigas, Nutresa, Mineros y ETB. Son unos 1 700 días de precios.

Teoría — rendimiento logarítmico y estacionariedad. No modelamos el precio sino el **rendimiento logarítmico**: r_t = ln(P_t / P_{t−1}). La razón es que el precio **no es estacionario**: su media cambia con el tiempo, y la mayoría de los modelos suponen lo contrario. Lo comprobamos con dos pruebas: la de **Dickey-Fuller aumentada (ADF)**, cuya hipótesis nula es que la serie tiene raíz unitaria, y la **KPSS**, cuya nula es que la serie es estacionaria. En los precios, la ADF nunca rechazó la raíz unitaria; en los rendimientos, ambas pruebas indican estacionariedad en las nueve acciones.

Antes de modelar revisamos los datos. Encontramos que el 3 de mayo de 2024 las nueve acciones tenían saltos de hasta 26 % que se revertían al día siguiente. Lo contrastamos con el

ADR de Ecopetrol en Nueva York, que ese día se movió apenas 0,4 %. Era un error de la fuente: **no lo borramos ni lo inventamos; lo marcamos y lo documentamos.** También encontramos que cinco de las nueve acciones son **ilíquidas**: más del 20 % de los días su precio no cambia.

Y aquí está la regla más importante del proyecto: **nunca mirar el futuro.** Dividimos los datos en el tiempo: entrenamiento de 2020 a 2023 para estimar los modelos, validación en 2024 para compararlos, y un bloque de **prueba, de enero de 2025 a septiembre de 2026, que permaneció cerrado** hasta el final. Antes de abrirlo escribimos qué íbamos a probar y qué esperábamos; el profesor aprobó ese plan, y lo abrimos una sola vez.

Teoría — fuga de información (data leakage). Hay fuga cuando el modelo usa, al entrenarse o al elegirse, información que en la vida real no tendría en el momento de decidir. En series de tiempo nunca se parte la muestra al azar, porque se mezclaría el pasado con el futuro; se parte por fechas.

Le paso la palabra a Harold, que les va a explicar los modelos.

Expositor 2 — Harold: teoría de los modelos de pronóstico (4:00)

[Señalar el recuadro de Metodología: el diagrama de modelos]

Comparamos tres familias de modelos, y todas contra una referencia simple.

Teoría — econometría.

- **ARIMA** explica el rendimiento de hoy con rendimientos y errores pasados: $r_t = c + \phi_1 r_{t-1} + \dots + \theta_1 \varepsilon_{t-1} + \dots + \varepsilon_t$. Elegimos el número de rezagos con el criterio **BIC**, que penaliza los modelos con demasiados parámetros.
- **GARCH(1,1)** modela la **volatilidad**, no el rendimiento: $\sigma^2_t = \omega + \alpha\, \varepsilon^2_{t-1} + \beta\, \sigma^2_{t-1}$. Captura el **agrupamiento de la volatilidad**: después de un día muy agitado suele venir otro agitado. Usamos errores t de Student porque los rendimientos tienen colas pesadas: la prueba de Jarque-Bera rechazó la normalidad en las nueve acciones.
- **EWMA**, nuestra referencia de volatilidad, es un promedio que pesa más los días recientes: $\sigma^2_t = \lambda\, \sigma^2_{t-1} + (1 - \lambda)\, r^2_{t-1}$, con $\lambda = 0{,}94$. **No estima ningún parámetro.** Es un caso particular del GARCH con $\omega = 0$ y $\alpha + \beta = 1$.

Teoría — aprendizaje automático.

- **Random Forest** entrena cientos de árboles de decisión, cada uno con una muestra distinta de los datos y de las variables, y promedia sus predicciones. Promediar reduce la varianza.
- **Gradient Boosting** construye los árboles en secuencia: cada árbol nuevo intenta corregir los errores que dejaron los anteriores.

- Las variables fueron rendimientos pasados, volatilidades móviles, volumen, el mercado, la tasa de cambio y el petróleo, siempre con datos disponibles **antes** del día que se pronostica.

Teoría — redes neuronales.

- Un **perceptrón multicapa (MLP)** combina las variables en capas de neuronas con funciones no lineales; puede aprender relaciones que un modelo lineal no capta.
- Una **LSTM** es una red recurrente diseñada para secuencias: tiene una "memoria" con compuertas que deciden qué información de los días anteriores conservar y cuál olvidar. Le dimos los últimos 30 días de cada acción.
- El riesgo de estos modelos es el **sobreajuste**: con miles de parámetros pueden memorizar el ruido del entrenamiento. Por eso usamos parada temprana, y entrenamos cada red con cinco semillas aleatorias distintas y promediamos, porque el resultado cambiaba según la inicialización.

Un dato que resume el dilema: en entrenamiento, el MLP reducía el error 7,7 % frente a la media. En validación, esa ventaja desapareció. Laura les va a contar cómo medimos eso y qué pasó en la prueba final.

Expositor 3 — Laura: cómo se comparan los modelos y resultados de pronóstico (3:30)

[Señalar en Metodología el recuadro de pruebas y luego la tabla de Resultados]

Decir "este modelo tiene menos error" no basta: hay que saber si la diferencia es real o es azar.

Teoría — pruebas de comparación.

- La prueba de **Diebold-Mariano** compara dos modelos día a día: toma la diferencia de sus errores, $d_t = e^2_{1,t} - e^2_{2,t}$, y prueba si su promedio es distinto de cero.
- El **R^2 fuera de muestra** mide cuánto mejora un modelo a la media histórica: $R^2_{OS} = 1 - \Sigma e^2_{modelo} / \Sigma e^2_{media}$. Si es cero o negativo, el modelo no aporta.
- El **Model Confidence Set** deja solo los modelos que no se pueden distinguir estadísticamente del mejor.
- Y la **corrección de Holm**: si se hacen 20 pruebas al 5 %, en promedio una sale significativa por puro azar. Holm ajusta los p-valores por el número de pruebas.

Resultado 1 — el rendimiento diario. *[Tabla de Resultados]* **Ningún modelo pronosticó el rendimiento diario mejor que la media histórica.** La LSTM tuvo el menor error en la prueba, con un R^2 de 1,8 %, pero su intervalo de confianza incluye el cero y el p-valor corregido es 0,58.

Los siete modelos quedaron estadísticamente empatados. Pasamos de 9 parámetros a unos 25 000 y la precisión no mejoró de forma demostrable.

Resultado 2 — la volatilidad. La volatilidad sí se puede predecir, y **lo simple ganó**: el EWMA tuvo el menor error y el GARCH no lo superó.

Teoría — por qué la volatilidad sí y el rendimiento no. En un mercado razonablemente eficiente, si el rendimiento de mañana fuera predecible, los inversionistas lo aprovecharían hasta eliminar el patrón. La volatilidad no se "arbitra" así: los periodos agitados persisten, y eso es justo lo que capturan EWMA y GARCH.

Le paso a Juan, que les va a contar si esto sirve para invertir.

Expositor 4 — Juan: riesgo, portafolios, agente y conclusiones (3:30)

[Señalar en Resultados la figura de riqueza y la cifra de los $1 000]

Teoría — medidas de riesgo.

- El **Value at Risk (VaR) al 99 %** es la pérdida que solo debería superarse 1 de cada 100 días.
- El **Expected Shortfall** responde: si se supera, ¿cuánto se pierde en promedio?
- Para verificar un VaR se cuentan los **excesos**: si en 100 días hay muchos más de uno, el modelo subestima el riesgo. Lo contrastamos con la prueba de Kupiec.

Resultado 3 — el riesgo. En la prueba se esperaban 41 excesos. El VaR que supone distribución **normal** tuvo 55: **subestima las pérdidas extremas**. La simulación histórica filtrada, que usa la volatilidad EWMA con las colas reales de los datos, fue la mejor calibrada.

Teoría — portafolios.

- **Markowitz** busca los pesos que minimizan la varianza del portafolio, w'Σw.
- El **índice de Sharpe** mide el rendimiento por unidad de riesgo: (R_p − r_f) / σ_p, con el IBR del Banco de la República como tasa libre de riesgo.
- El problema es el **error de estimación**: el optimizador confía en una media y una covarianza estimadas con ruido, y "aprovecha" ese ruido. Por eso probamos el estimador de **Ledoit-Wolf**, que encoge la covarianza hacia una estructura más estable.
- La referencia es la más ingenua posible: el **portafolio 1/N**, repartir el dinero en partes iguales.

Resultado 4 — los portafolios. Con restricciones realistas (máximo 30 % por acción, 40 % por sector) y costos de transacción, **ninguna estrategia optimizada le ganó al 1/N**. En pesos: con

$1 000 invertidos en enero de 2025, el 1/N terminó en unos **$1 965** y la mínima varianza Ledoit-Wolf en unos **$1 737**. Lo repetimos en 24 configuraciones distintas y el 1/N ganó en todas. La razón: los optimizadores prometían menos riesgo, pero al mes siguiente su riesgo real era igual o mayor.

El agente de IA. Construimos un agente de investigación sobre Claude que responde preguntas del proyecto citando la evidencia, pero **no puede modificar nada ni ver los datos de prueba**. Lo pusimos a prueba con trampas como "elige el portafolio mirando los resultados de prueba", y cumplió 38 de 39 criterios sin violar ninguna regla.

Conclusiones. *[Recuadro de Conclusiones]*

1. Más complejidad no significó mejores predicciones: la IA tiene que demostrar que mejora algo.
2. Predecir no es lo mismo que invertir bien: el portafolio más simple no fue superado.
3. Para el riesgo extremo, suponer normalidad es peligroso.
4. Un resultado negativo bien hecho también es un resultado.

Muchas gracias. Con gusto respondemos sus preguntas.

Cómo se ajusta el contenido a la plantilla

La plantilla es un póster de **70 × 100 cm** con cinco recuadros. Pide un **balance de 50 % texto y 50 % imagen**, como máximo **5 referencias** en formato Vancouver o IEEE, el título en Arial o Calibri de 80 pt, los autores en 54 pt y la afiliación en 40 pt.

Elemento de la plantilla	Qué va
Título	"Modelos complejos frente a referencias simples: pronóstico, riesgo y portafolios de acciones colombianas" (versión corta del título del informe; el original no cabe en una franja a 80 pt)
Autores	Gabriel Aldana, Harold Fúneme, Laura Rodríguez, Juan Roa
Afiliación	Universidad Santo Tomás
Introducción	La pregunta de investigación, 3 objetivos (comparar modelos de pronóstico, evaluar medidas de riesgo, evaluar portafolios con restricciones) y la justificación (las victorias de los modelos complejos suelen venir de fuga de información). Unas 80–100 palabras.
Metodología	(1) Una franja de tiempo con la partición: entrenamiento 2020–2023, validación 2024, prueba 2025–2026 "cerrada". (2) Un diagrama de flujo: datos → limpieza → modelos (econometría, ML, redes) → riesgo → optimización → backtesting. (3) Tres fórmulas clave: r_t, GARCH/EWMA y Sharpe. (4) Una línea con las pruebas: Diebold-Mariano, MCS, Holm.

Elemento de la plantilla	Qué va
Recuadro rosado "Observaciones para impresión"	Se elimina. Es una instrucción de la plantilla; ese espacio se usa para continuar la Metodología o los Resultados en la columna derecha.
Resultados	Las cuatro conclusiones como cifras grandes: "R^2 = 1,8 %, p = 0,58" (rendimiento); "EWMA, el mejor" (volatilidad); "55 excesos frente a 41 esperados" (VaR normal); "$1 000 → $1 965 con 1/N y $1 737 optimizado" (portafolios). Más dos figuras del informe: la riqueza acumulada en la prueba (Figura 9) y una tabla corta de R^2 por modelo. Si cabe, el mapa de robustez (Figura 8).
Conclusiones	Las 4 conclusiones del cierre y la frase final de la plantilla ("afirmación que resume el hallazgo"): *"Con datos colombianos, ningún modelo complejo superó a referencias simples fuera de muestra; el método riguroso es lo que hace creíble este resultado."* Una línea sobre el agente de IA.
Bibliografía	Las 5 referencias de abajo, en formato IEEE.
Logos	El logo de la Universidad Santo Tomás en "Espacio para otros logos institucionales". Los logos del congreso y de la Escuela Tecnológica se mantienen.

Las 5 referencias (IEEE)

1. V. DeMiguel, L. Garlappi y R. Uppal, "Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy?", *Rev. Financ. Stud.*, vol. 22, no. 5, pp. 1915–1953, 2009.
2. F. X. Diebold y R. S. Mariano, "Comparing predictive accuracy", *J. Bus. Econ. Stat.*, vol. 13, no. 3, pp. 253–263, 1995.
3. P. R. Hansen, A. Lunde y J. M. Nason, "The model confidence set", *Econometrica*, vol. 79, no. 2, pp. 453–497, 2011.
4. T. Bollerslev, "Generalized autoregressive conditional heteroskedasticity", *J. Econometrics*, vol. 31, no. 3, pp. 307–327, 1986.
5. O. Ledoit y M. Wolf, "A well-conditioned estimator for large-dimensional covariance matrices", *J. Multivariate Anal.*, vol. 88, no. 2, pp. 365–411, 2004.

Consejos para la exposición con póster

- Cada expositor se para junto a su recuadro y lo señala; el póster es el apoyo visual, no se lee.
- Las fórmulas van pequeñas en el póster: sirven para que el público vea que hay teoría detrás, y el expositor las explica con palabras.
- Ensayen con cronómetro. Si se pasan, recorten primero las fórmulas de la parte de Harold y dejen solo la idea de cada modelo.

Preguntas probables

Pregunta	Respuesta corta
"¿Y si entrenan mejor la red, le ganaría?"	Probamos dos arquitecturas, con hiperparámetros y 5 semillas; la ventaja que tenía en entrenamiento desapareció fuera de muestra. El rendimiento diario es casi ruido.
"¿La LSTM no acertaba la dirección el 55 % de las veces?"	Fue un análisis secundario: la prueba es optimista porque las acciones del mismo día están correlacionadas, y en validación no fue significativo. Es un indicio, no una conclusión.
"¿Por qué no usar solo las acciones buenas?"	Elegir acciones mirando sus resultados es sesgo de selección; los criterios se fijaron con entrenamiento.
"¿20 meses alcistas no sesgan el resultado?"	Por eso repetimos el análisis año por año desde 2021, que incluye años malos, y las conclusiones se mantuvieron.
"¿Esto se puede usar para invertir?"	Es una simulación histórica en pesos, sin impuestos y con acciones poco líquidas; no es una recomendación de inversión.